

Introducción a la Inteligencia Artificial

Organización del curso y panorama de contenidos

Juan Pardo (Machine Learning)
Antonio Falcó (Deep Learning y Procesamiento de Imágenes)

Máster de Formación Permanente en IA y Fabricación Aditiva

13 de octubre de 2025

Visión general del curso

- Objetivo: proporcionar fundamentos prácticos y teóricos de **Machine Learning** (ML) y **Deep Learning** (DL).
- Hilo conductor: **procesamiento de imágenes** como motivación y ejemplo transversal.
- Dos bloques coordinados (6 sesiones cada uno):
 - **ML** (responsable: *Juan Pardo*).
 - **DL + Procesamiento de Imágenes** (responsable: *Antonio Falcó*).

Mapa de la sesión

1 Estructura y responsabilidades

2 Evaluación y recursos

Distribución por docentes

Juan Pardo — Machine Learning (6 sesiones)

- Fundamentos de aprendizaje supervisado/no supervisado
- Modelos clásicos: regresión (lineal/logística), KNN, SVM
- Árboles de decisión y Random Forest
- Clustering (K-means) y reducción de dimensión (PCA)
- Métricas de evaluación y validación cruzada

Antonio Falcó — Deep Learning e Imagen (6 sesiones)

- Motivación con procesamiento de imágenes (filtros/convoluciones)
- Redes neuronales: MLP, entrenamiento y optimización
- Redes Convolucionales (CNN): arquitecturas y casos
- Transfer learning en visión
- **Transformers**: atención, ViT y multimodalidad

Calendario orientativo y flujo

- **Sesión 1 (Antonio):** Motivación con imágenes; operaciones básicas y filtros.
- **Sesiones 2–7 (Juan, 6 sesiones):** Fundamentos de ML, modelos clásicos y evaluación.
- **Sesiones 8–13 (Antonio, 6 sesiones):** Redes neuronales, CNNs, transferencia y **Transformers**.

Conexiones

La parte de imágenes introduce *convoluciones* clásicas y enlaza con **CNNs**; posteriormente se presenta la **atención** y los **Transformers** como estado del arte.

Mapa de la sesión

1 Estructura y responsabilidades

2 Evaluación y recursos

Evaluación

- **Prácticas guiadas** (notebooks): implementación de métodos y análisis.
- **Mini-proyecto** opcional: problema aplicado (preferente en visión).
- **Criterios** (orientativo): participación 10 %, prácticas 60 %, mini-proyecto 30 %.

Recursos y herramientas

- **Repositorio de la asignatura:** material y notebooks (Colab/Jupyter).
- Librerías: NumPy, scikit-learn, matplotlib, PyTorch/TensorFlow.
- Lecturas recomendadas y enlaces a datasets públicos de imagen.

Mapa de la sesión

3 Procesamiento de imágenes (motivación)

4 Machine Learning (visión general)

5 Deep Learning

6 Cierre

¿Qué es una imagen digital?

- Matrices de píxeles (escala de grises o RGB) y resolución.
- Histograma: brillo, contraste y rango dinámico.

Operaciones básicas

Ajuste de brillo/contraste y **umbral** (binarización).

Filtros y *convoluciones* clásicas

- Núcleos (kernels) y convolución discreta.
- Detección de bordes (Sobel, Laplaciano) y suavizado (media, Gaussiano).
- Limitaciones: filtros fijos vs **filtros aprendidos** en CNN.

Mapa de la sesión

3 Procesamiento de imágenes (motivación)

4 Machine Learning (visión general)

5 Deep Learning

6 Cierre

Problemas y enfoques en ML

- Supervisado (regresión/clasificación) vs no supervisado (clustering, PCA).
- Pipeline: preprocesado, división de datos, entrenamiento, validación, test.
- Métricas: accuracy, precisión/recobrado, AUC, RMSE.

Modelos clásicos

Regresión y clasificación

- Regresión lineal y regularización (Ridge/Lasso)
- Regresión logística
- KNN y SVM

Estructuras y reducción

- Árboles de decisión y Random Forest
- Clustering: K-means
- PCA: componentes principales

Mapa de la sesión

- 3 Procesamiento de imágenes (motivación)
- 4 Machine Learning (visión general)
- 5 Deep Learning**
- 6 Cierre

De MLP a redes profundas

- Perceptrón, funciones de activación y **backpropagation**.
- Entrenamiento: optimizadores (SGD, Adam), tasa de aprendizaje, regularización.
- Ventaja: aprendizaje de **representaciones** a partir de los datos.

Redes Convolucionales (CNN)

- Capas de convolución, activación y *pooling*.
- Arquitecturas icónicas: LeNet, AlexNet, VGG, ResNet (visión general).
- Casos de uso: clasificación, segmentación, detección de objetos.

Transformers y atención

- **Atención y self-attention:** idea clave y beneficio.
- Arquitecturas: Encoder, Decoder y Encoder–Decoder.
- **Vision Transformers (ViT):** imágenes como parches + embeddings.
- Multimodalidad: texto–imagen y agentes generativos (panorama general).

Mapa de la sesión

3 Procesamiento de imágenes (motivación)

4 Machine Learning (visión general)

5 Deep Learning

6 Cierre

Ruta del curso: de la imagen a Transformers



Recursos y próximos pasos

- Notebooks introductorios (Colab) para imagen, ML y DL.
- Repositorio con datasets y guías de práctica.
- Lecturas: capítulos introductorios y reseñas de ViT/Transformers.